IPADS INSTITUTE OF PARALLEL AND DISTRIBUTED SYSTEMS

上海交通大学 SHANGHAI JIAO TONG UNIVERSITY

中断、异常与系统调用

陈海波 / 夏虞斌

上海交通大学并行与分布式系统研究所

https://ipads.se.sjtu.edu.cn

版权声明

- 本内容版权归**上海交通大学并行与分布式系统研究所**所有
- 使用者可以将全部或部分本内容免费用于非商业用途
- 使用者在使用全部或部分本内容时请注明来源
  - 资料来自上海交通大学并行与分布式系统研究所+材料名字
- 对于不遵守此声明或者其他违法使用本内容者，将依法保留追究权
- 本内容的发布采用 Creative Commons Attribution 4.0 License
  - 完整文本：https://creativecommons.org/licenses/by/4.0/legalcode

回顾：ARMv8

- **扩大物理寻址**
  - 4GB以外的物理地址
- **64位虚拟地址**
- **自动事件信号**
  - 低功耗、高性能的自旋锁
- **硬件加速加密**
- **新的异常模型**

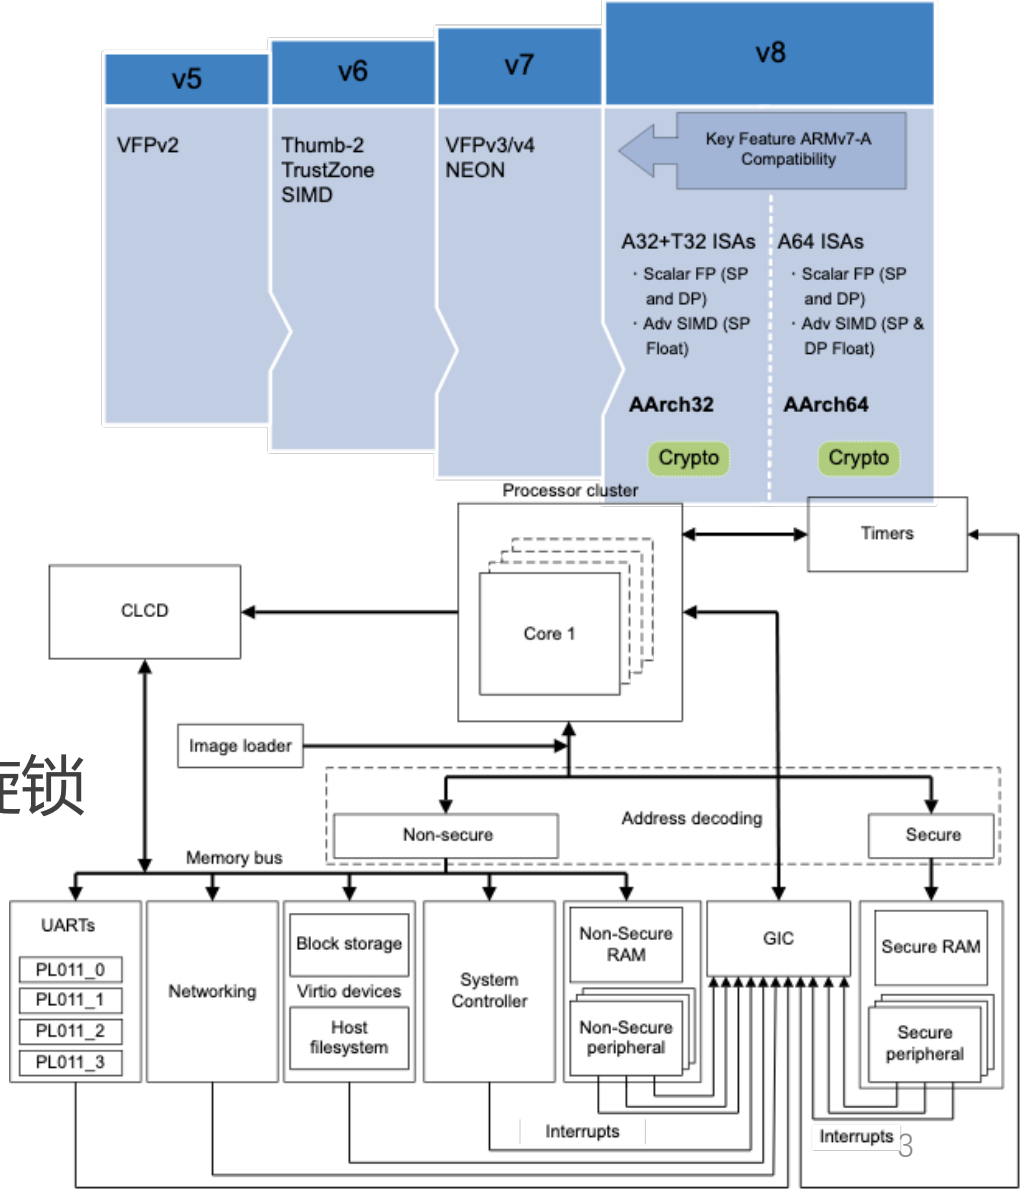

回顾：特权级/ARM (Exception Level)

低

- EI0: 用户态程序
- EI1: 内核
- EI2: hypervisor
- EI3: monitor

高

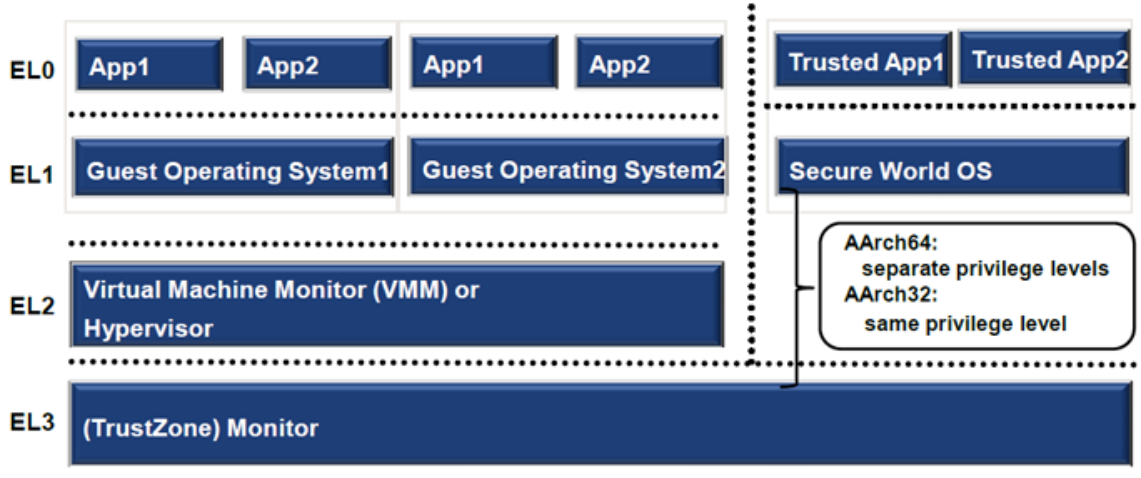

回顾：ChCore对异常级别的使用

低

- EL0：ChCore中的用户程序
- EL1：ChCore中的内核代码
- EL2：未使用
- EL3：未使用

高

回顾：设备上电后……

- **OS如何启动**
  - 不同ARM设备启动OS的方式不同，例
  - Raspi 3: GPU进行初始化后从SD卡上加载
  - Hikey970: 通过BL链和UEFI加载
- **OS启动时进行硬件初始化工作，并开启页表**
- **进入内核**

初始化页表并开启MMU

- **初始化页表并开启MMU**
  - 将kernel代码映射到低地址段（和物理地址相同）和高地址段两份

思考：为何需要将kernel代码同时映射到低地址段和高地址段两份？

```
/* Setup page tables */
adrp    x8, _boot_pgd_down
msr     ttbr0_el1, x8
adrp    x8, _boot_pgd_up
msr     ttbr1_el1, x8
isb

/* invalidate all TLB entries for EL1 */
tlbi    vmalle1is
dsb     ish
isb

enable_mmu sctlr_el1 , x8
```

进入kernel

- 跳转到kernel的main函数

```
BEGIN_FUNC(start_kernel)
    /*
     * Code in bootloader specified only the primary
     * cpu with MPIDR = 0 can be boot here. So we directly
     * set the TPIDR_EL1 to 0, which represent the logical
     * cpuid in the kernel
     */
    mov     x3, #0
    msr     TPIDR_EL1, x3

    ldr     x2, =kernel_stack
    add     x2, x2, KERNEL_STACK_SIZE
    mov     sp, x2
    bl      main
END_FUNC(start_kernel)
```

Kernel

- 真正进入ChCore
- 开启OS的各种服务
  - 后续课程会介绍

```c
void main(void *addr)
{
  u32 ret = 0;

  /* Init uart */
  uart_init();
  kinfo("[ChCore] uart init finished\n");

  /* Init exception vector */
  arch_interrupt_init();
  kinfo("[ChCore] interrupt init finished\n");

  /* Init mm */
  mm_init(NULL);
  kinfo("[ChCore] mm init finished\n");

  /* Init big kernel lock */
  ret = lock_init(&big_kernel_lock);
  kinfo("[ChCore] lock init finished\n");
  BUG_ON(ret != 0);

  /* Init scheduler with specified policy */
  sched_init(&rr);
  // sched_init(&pbrr);
  kinfo("[ChCore] sched init finished\n");

  /* Create initial thread here, which use the `init.bin` */
  create_root_thread("/init.bin");
  kinfo("[ChCore] root thread init finished\n");

  /* Other cores are busy looping on the addr, wake up those cores */
  enable_smp_cores(addr);
  kinfo("[ChCore] boot multicore finished\n");

  /* Enable PMU by setting PMCR_EL0 register */
  pmu_init();
  kinfo("[ChCore] pmu init finished\n");
```

X86-64的启动过程

- **为了向前兼容，内核启动中存在兼容性工作**
- **通过段寄存器，进行模式转换**
  - 实模式(16-bit)
  - 保护模式(32-bit)
  - IA32E (64-bit)
- **由于实模式的内存限制(64KB)，再将内核代码按段拷贝到内存中**
- **进入内核**

硬件模拟

使用模拟器进行开发

- **ARM模拟器**
  - 仅用软件完全实现硬件行为
  - 如同跑在真正的ARM硬件上

像跑在host OS上的普通程序

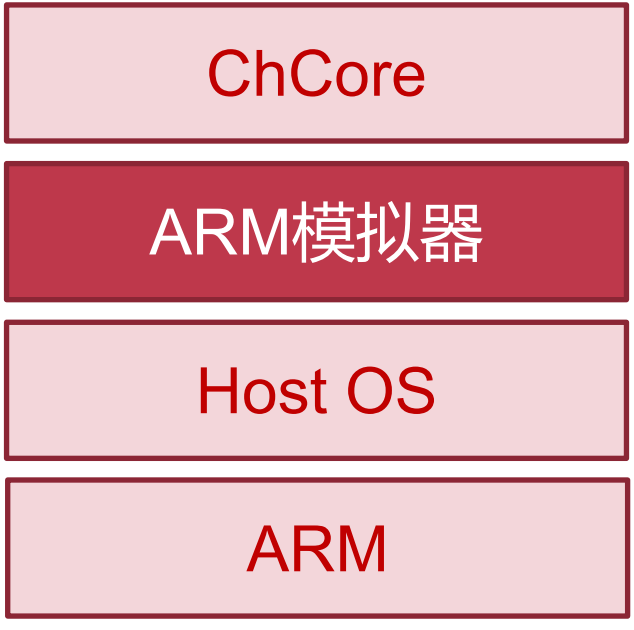

模拟CPU

```
switch (opcode) {
case 0x10: /* ADD, SUB */
    if (u) {
        (tcg_rd, tcg_rn, tcg_rm);
    } else {
        tcg_gen_add_i64(tcg_rd, tcg_rn, tcg_rm);
    }
    break;
case 0x1: /* SQADD */
    if (u) {
        gen_helper_neon_qadd_u64(tcg_rd, cpu_env, tcg_rn, tcg_rm);
    } else {
        gen_helper_neon_qadd_s64(tcg_rd, cpu_env, tcg_rn, tcg_rm);
    }
    break;
case 0x5: /* SQSUB */
    if (u) {
        gen_helper_neon_qsub_u64(tcg_rd, cpu_env, tcg_rn, tcg_rm);
    } else {
        gen_helper_neon_qsub_s64(tcg_rd, cpu_env, tcg_rn, tcg_rm);
    }
    break;
```

OPCODE_ADD

模拟寄存器

```
typedef struct CPUARMState {
    /* Regs for current mode.  */
    uint32_t regs[16];

    /* 32/64 switch only happens when taking and returning from
     * exceptions so the overlap semantics are taken care of then
     * instead of having a complicated union.
     */
    /* Regs for A64 mode.  */
    uint64_t xregs[32];
    uint64_t pc;
```

模拟内存

```
AbstractMemory::access(PacketPtr pkt)
{

    assert(pkt->getAddrRange().isSubset(range));

    uint8_t *host_addr = toHostAddr(pkt->getAddr());

    if (pkt->isRead()) {
        assert(!pkt->isWrite());
        if (pkt->isLLSC()) {
            assert(!pkt->fromCache());
            // if the packet is not coming from a cache then we have
            // to do the LL/SC tracking here
            trackLoadLocked(pkt);
        }
        if (pmemAddr) {
            pkt->setData(host_addr);
        }
        TRACE_PACKET(pkt->req->isInstFetch() ? "IFetch" : "Read");
        stats.numReads[pkt->req->masterId()]++;
        stats.bytesRead[pkt->req->masterId()] += pkt->getSize();
        if (pkt->req->isInstFetch())
            stats.bytesInstRead[pkt->req->masterId()] += pkt->getSize();
    } else if (pkt->isInvalidate() || pkt->isClean()) {
        assert(!pkt->isWrite());
        // in a fastmem system invalidating and/or cleaning packets
        // can be seen due to cache maintenance requests

        // no need to do anything
```

MEM_READ

模拟设备

- 硬盘：host OS的文件
- VGA显示：host OS的显示窗口
- 键盘：host OS的键盘API
- 时钟芯片：host OS的时钟
- ……

为何需要模拟器？

- **测试与调试**
- **提高资源利用率**

- **正如IBM的虚拟化**
  - IBM’s M44/44X，1960s

从键盘看I/O

问题：应用如何通过OS和外设交互的？

- 简单场景：应用是如何获得键盘输入？

OS接受键盘输入

- **键盘等外设具有控制器和缓冲区，将输入存入缓冲区**
- **OS获取该输入的可能方法……**
  - 轮询：OS不断去读该缓冲区中的值
  - 中断：当控制器接收到输入后，打断CPU正常执行，OS进行处理

思考：就键盘而言，选用哪种方式更好？为什么？

思考：在哪种场景下，使用“轮询”的效果更好？

应用用从OS获取输入

- **为了给应用屏蔽硬件细节、管理硬件，应用一般不直接操控设备**
- **`getchar()`中调用`read()`请求OS将获取的输入返回给用户**
- **应用能否绕过OS直接控制硬件？**
  - 用户态驱动 (但是也需要操作系统实现配置)

通用概念

- **中断（Interrupt）**
  - 外部硬件设备所产生的信号
  - 异步：产生原因和当前执行指令无关，如程序被磁盘读打断
- **异常（Exception）**
  - 软件的程序执行而产生的事件
  - 包括系统调用（System Call）
    - 用户程序请求操作系统提供服务
  - 同步：产生和当前执行或试图执行的指令相关

不同体系结构术语的对应关系

通用概念	产生原因	AArch64		x86-64
中断	硬件异步	异常	异步异常（重置/中断）	中断（可屏蔽/不可屏蔽）
异常	软件同步		同步异常（终止/异常指令）	异常（Fault/Trap/Abort）

- **之后提到的“中断”、“异常”均为通用概念意义**

AArch64的中断（异步异常）

- **重置（Reset）**
  - 最高级别的异常，用以执行代码初始化CPU核心
  - 由系统首次上电或控制软件、Watchdog等触发
- **中断（Interrupt）**
  - CPU外部的信号触发，打断当前执行
  - 如计时器中断、键盘中断等

AArch64的（同步）异常

- **中止（Abort）**
  - 失败的指令获取或数据访问
  - 如访问不可读的内存地址等
- **异常产生指令（Exception generating instructions）**
  - SVC：用户程序 -> 操作系统
  - HVC：客户系统 -> 虚拟机管理器
  - SMC：Normal World -> Secure World

x86-64术语

- **中断（设备产生、异步）**
  - 可屏蔽：设备产生的信号，通过中断控制器与处理器相连，可被暂时屏蔽（如，键盘、网络事件）
  - 不可屏蔽：一些关键硬件的崩溃（如，内存校验错误）
- **异常（软件产生、同步）**
  - **错误（Fault）：**如缺页异常（可恢复）、段错误（不可恢复）等
  - **陷阱（Trap）：**无需恢复，如断点（int 3）、系统调用（int 80）
  - **中止（Abort）：**严重的错误，不可恢复（机器检查）

中断的产生

中断控制器

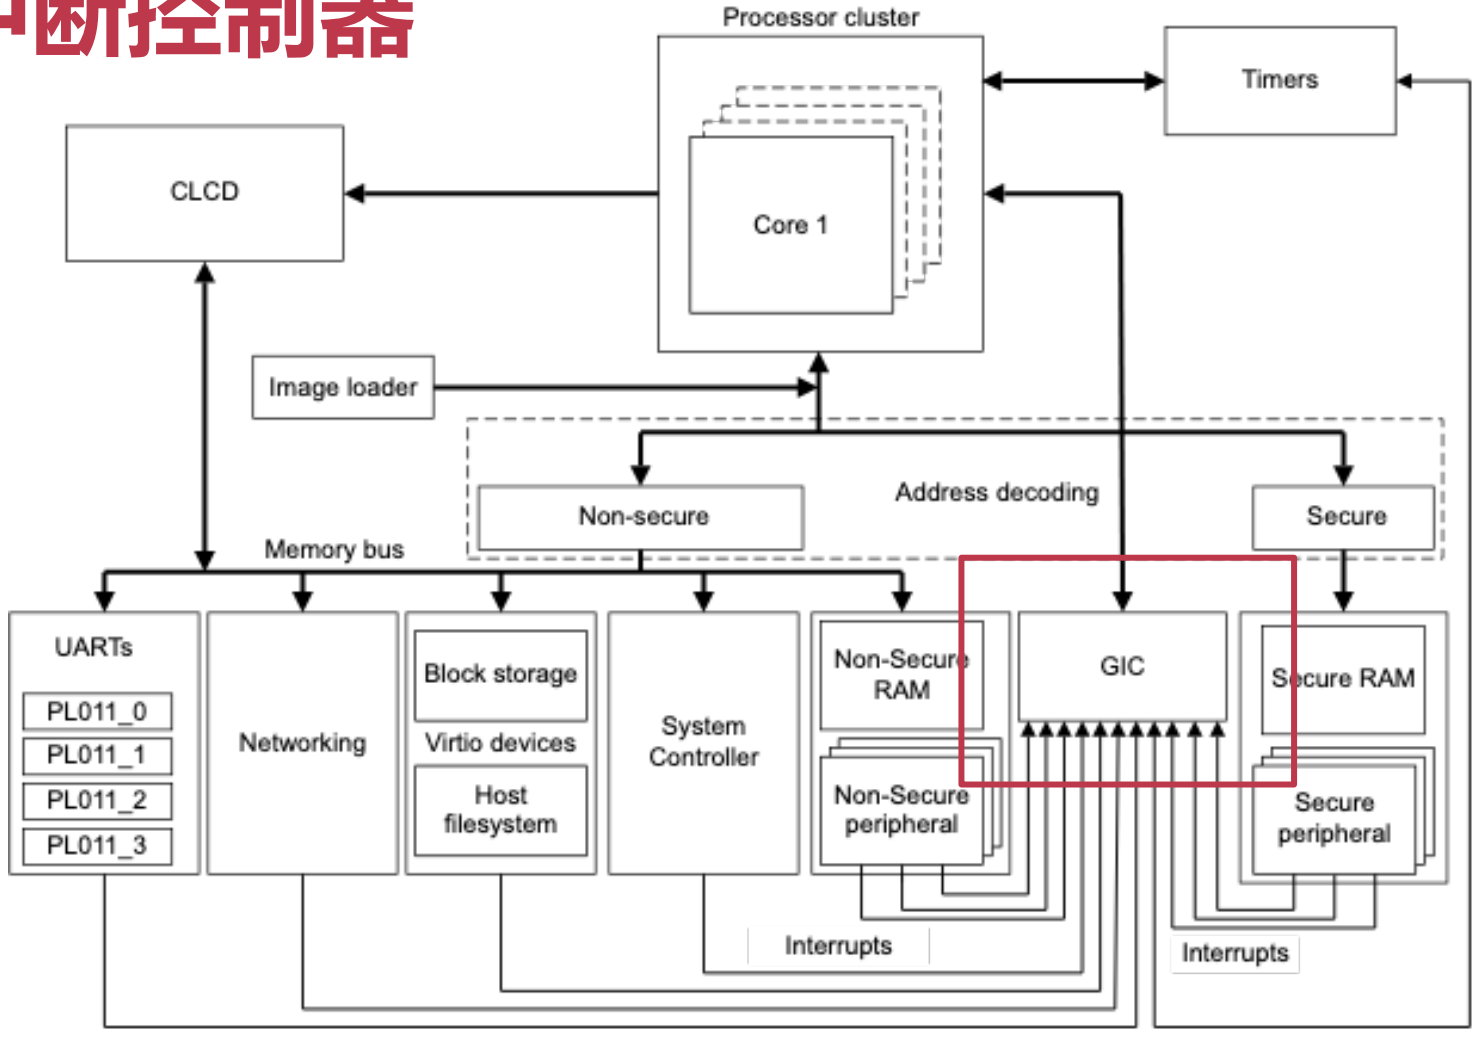
Processor cluster
Timers
CLCD
Core 1
Image loader
Address decoding
Non-secure
Secure
Memory bus
UARTs
PL011_0
PL011_1
PL011_2
PL011_3
Networking
Block storage
Virtio devices
Host filesystem
System Controller
Non-Secure RAM
Non-Secure peripheral
GIC
Secure RAM
Secure peripheral
Interrupts
Interrupts

中断控制器需要考虑的问题

- **如何指定不同中断的优先级**
  - 低优先级中断处理中，出现了高优先级的中断
  - 嵌套中断
- **中断交给谁处理**
- **如何与软件协同**

AArch64中断的分类

- **IRQ（Interrupt Request）**
  - 普通中断，优先级低，处理慢
- **FIQ（Fast Interrupt Request）**
  - 一次只能有一个FIQ
  - 快速中断，优先级高，处理快
  - 常为可信任的中断源预留

连接CPU的不同针脚

可在中断控制器（Interrupt Controller）中配置

- **SError（System Error）**
  - 原因难以定位、较难处理的异常，多由异步中止（Abort）导致
  - 如从缓存行（Cacheline）写回至内存时发生的异常

早期的ARM中断控制器

- **厂商指定模型**
  - 将中断路由给处理器的功能由SoC(System-on-a-Chip)厂商实现
  - FIQ直接发给处理器，IRQ根据优先级进行分发
  - 如Freescale/NXP iMx233/iMx28系列中的ICOLL

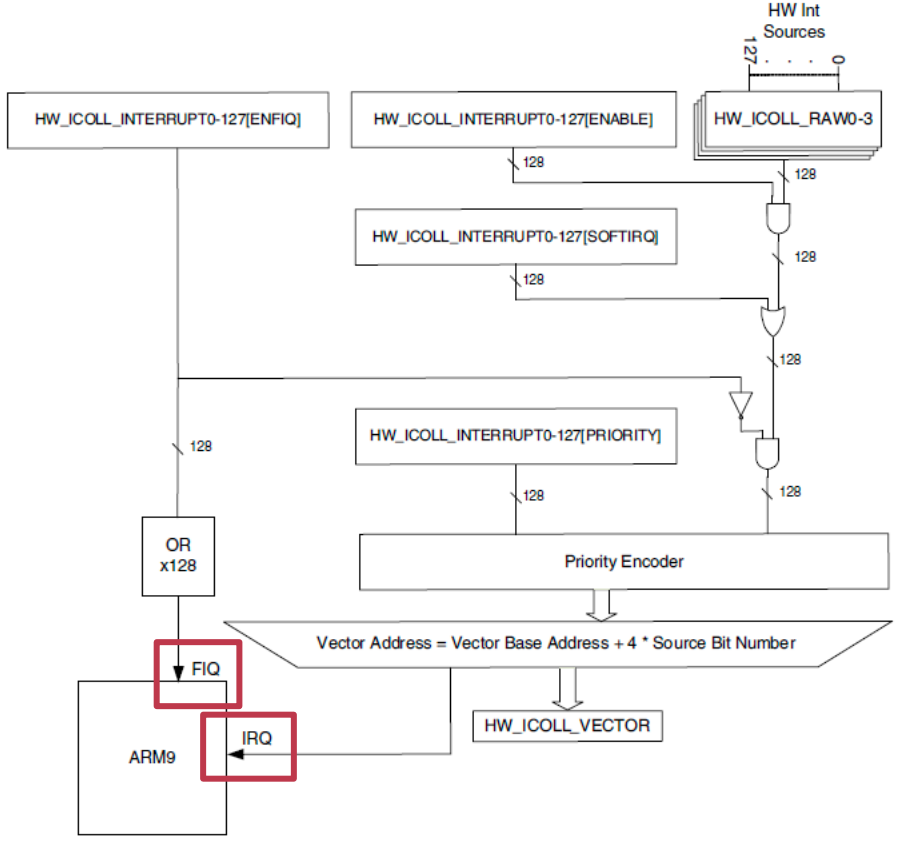

早期的ARM中断控制器

- **向量中断控制器 VIC (Vector Interrupt Controller)**
  - ARM提出
  - 放在AMBA (Advanced Microcontroller Bus Architecture)高速总线上
  - 32种非向量中断（不同中断相同的处理入口）
  - 16种向量中断（不同中断不同的处理入口）

向量中断与非向量中断

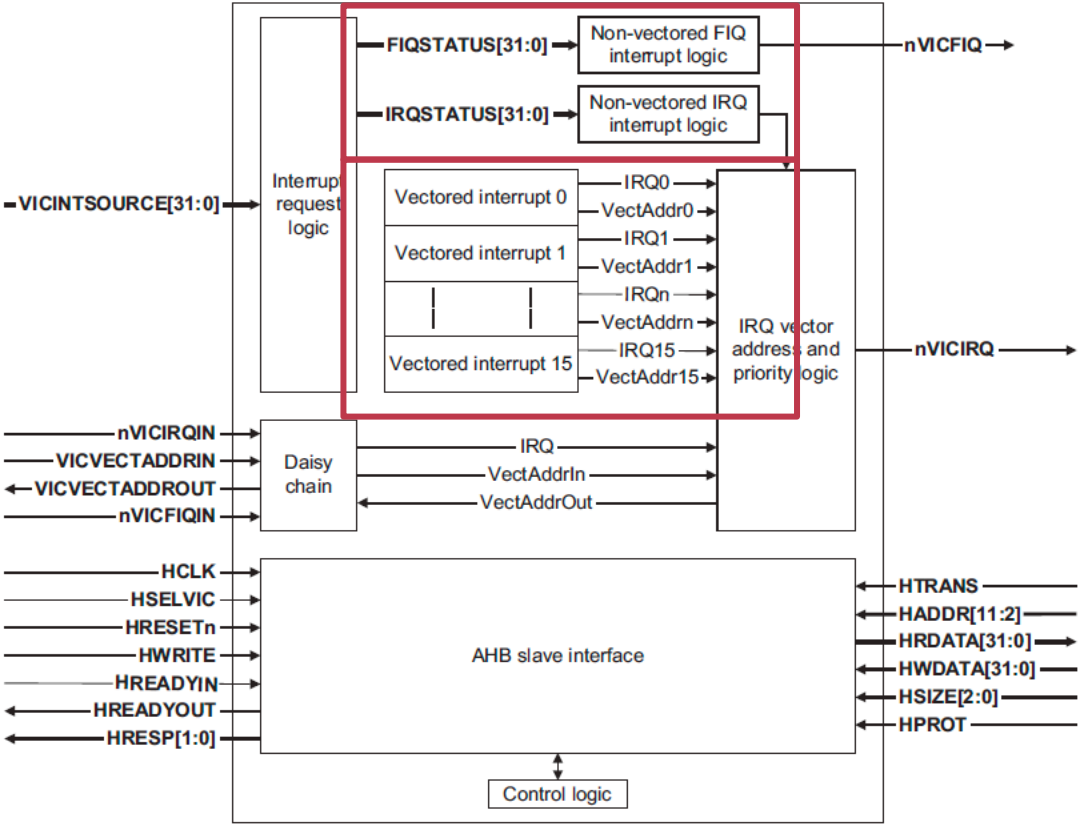
FIQSTATUS[31:0]
Non-vectored FIQ interrupt logic
nVICFIQ
IRQSTATUS[31:0]
Non-vectored IRQ interrupt logic
VICINTSOURCE[31:0]
Interrupt request logic
Vectored interrupt 0
Vectored interrupt 1
Vectored interrupt 15
IRQ0
VectAddr0
IRQ1
VectAddr1
IRQn
VectAddrn
IRQ15
VectAddr15
IRQ vector address and priority logic
nVICIRQ
nVICIRQIN
VICVECTADDRIN
VICVECTADDROUT
nVICFIQIN
Daisy chain
IRQ
VectAddrIn
VectAddrOut
HCLK
HSELVIC
HRESETn
HWRITE
HREADYIN
HREADYOUT
HRESP[1:0]
AHB slave interface
HTRANS
HADDR[11:2]
HRDATA[31:0]
HWDATA[31:0]
HSIZE[2:0]
HPROT
Control logic

GIC: 通用中断控制器

- **中断类型变多，将中断分发给不同的核（对称或非对称）进行处理**

- **主要功能**
  - 分发：管理所有中断、决定优先级、路由
  - CPU接口：给每个CPU核有对应的接口

GIC中断来源

SPI：共享设备中断

- 由所有CPU共同连接的设备触发
- 可以被路由到一个或多个核，找到可用的核进行处理
- Distributor可配置路由
- 如UART中断
- 中断ID：32-1019 4096-5119

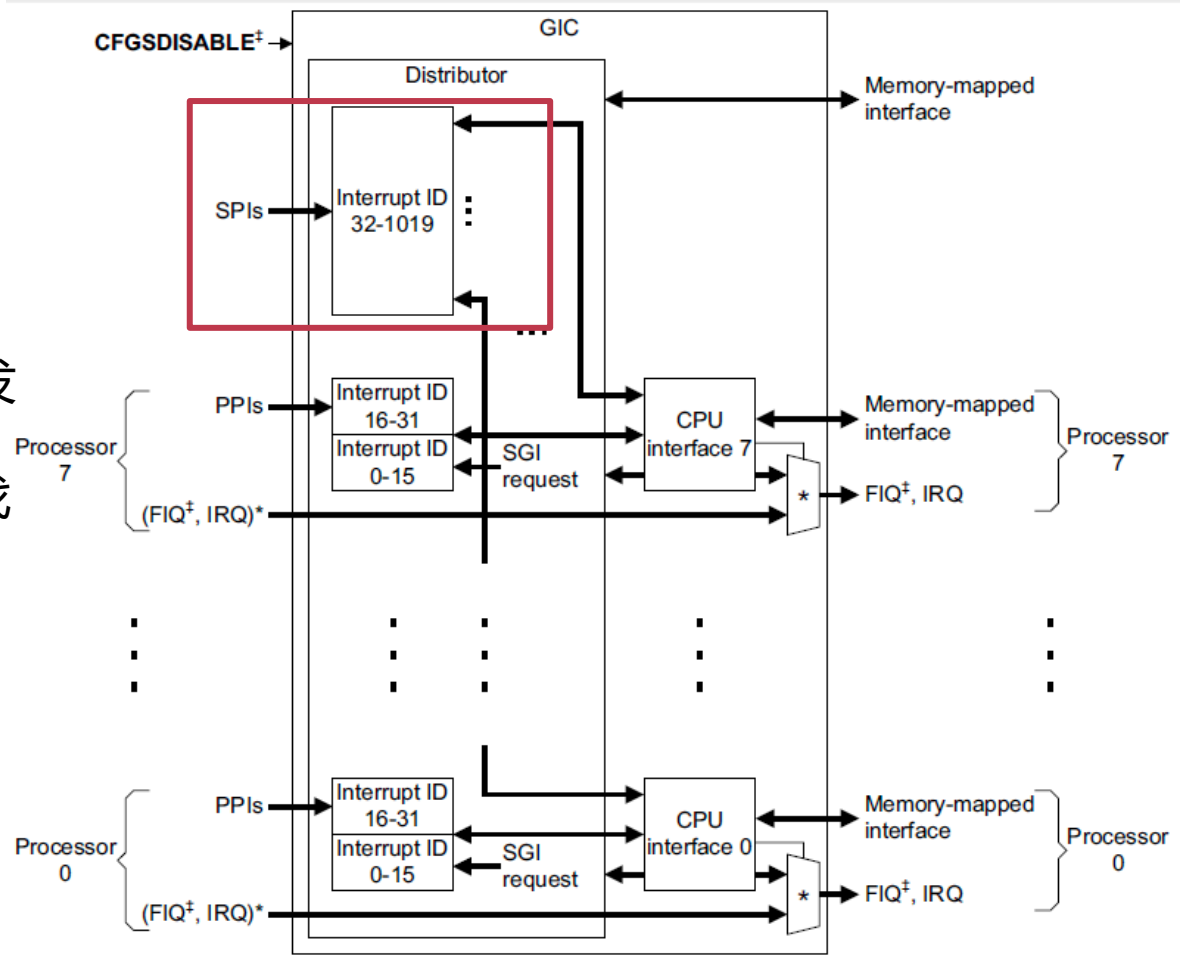

GIC中断来源

PPI：私有设备中断

- 由每个处理器核上的私有设备触发
- 指定核处理
- 如通用定时器（Generic Timer）
- 中断ID：16-31 1056-5119

SGI：软件产生中断

- 发送核间中断进行通信
- 中断ID：0-15

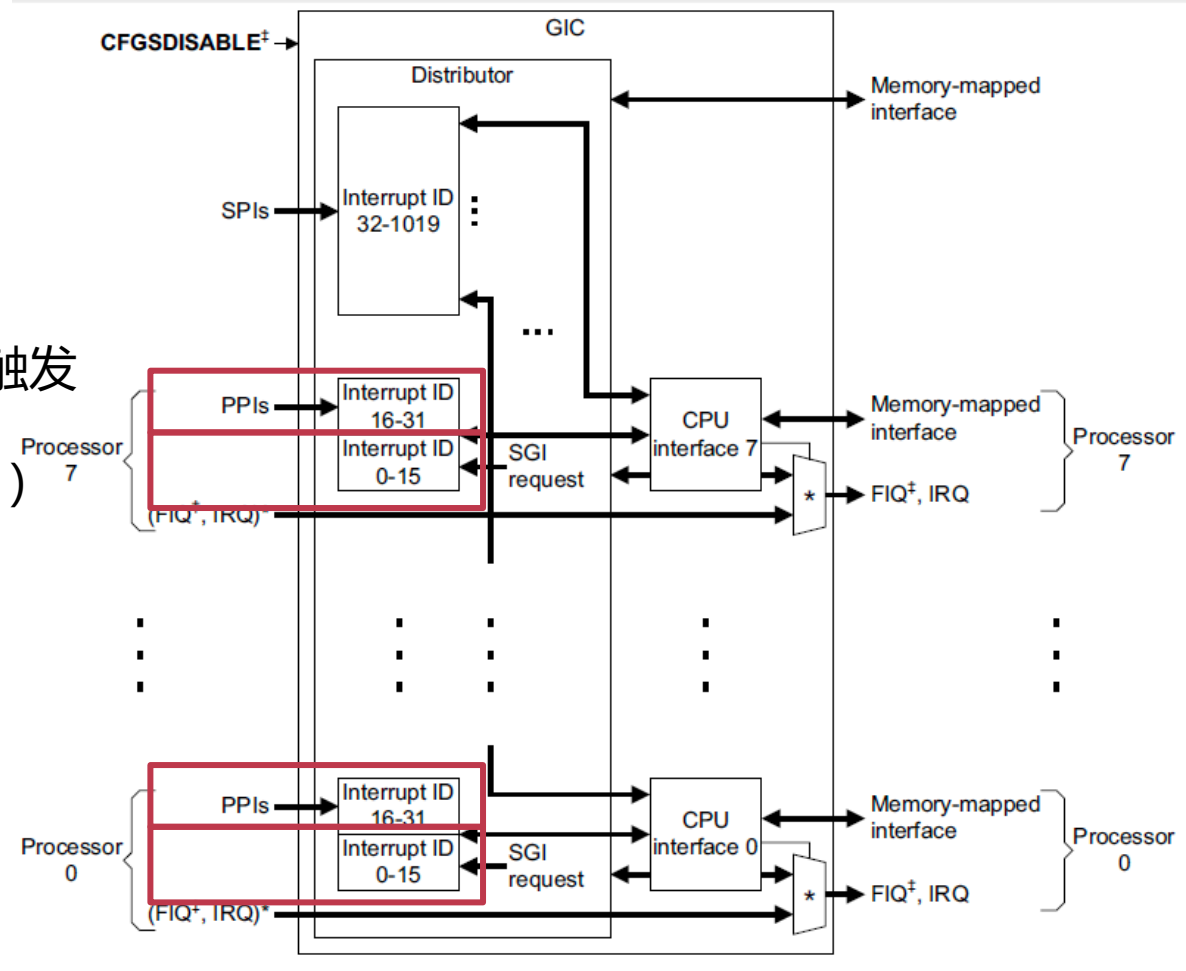

GIC的路由配置 – 以启用timer为例

```
BEGIN_FUNC(put32)
    str w1,[x0]
    ret
END_FUNC(put32)
```

使用MMIO，设置GIC中寄存器，启用timer

```
#define GICD_ISENABLER  (KBASE+0xE82B1100)

void plat_interrupt_init(void)
{
    u32 cpuid = smp_get_cpu_id();

    if (cpuid == 0)
        gicv2_dist_init();

    gicv2_cpu_init();

    /* 启用timer */
    put32(GICD_ISENABLER, 0x08000000);
    timer_init();

}
```

GIC中断信息获取

使用MMIO，从GIC中的寄存器里获得中断信息

```
void plat_handle_irq(void)
{
    u32 cpuid = 0;
    unsigned int irq_src, irq;

    cpuid = smp_get_cpu_id();
    irq_src = get32(core_irq_source[cpuid]);

    irq = 1 << ctzl(irq_src);
    switch (irq) {
    case INT_SRC_TIMER3:
        handle_timer_irq();
        break;
    default:
        kinfo("Unsupported IRQ %d\n", irq);
    }
    return;
```

```
#define CORE_IRQ_BASE           (KBASE + 0x40000060)
#define CORE0_IRQ_SOURCE        (CORE_IRQ_BASE + 0x0)
#define CORE1_IRQ_SOURCE        (CORE_IRQ_BASE + 0x4)
#define CORE2_IRQ_SOURCE        (CORE_IRQ_BASE + 0x8)
#define CORE3_IRQ_SOURCE        (CORE_IRQ_BASE + 0xc)

u64 core_irq_source[PLAT_CPU_NUM] = {
    CORE0_IRQ_SOURCE,
    CORE1_IRQ_SOURCE,
    CORE2_IRQ_SOURCE,
    CORE3_IRQ_SOURCE
};
```

讨论：中断处理不能做太多的事情？

- 怎么办？

案例：Linux的中断处理理念

- **在中断处理中做尽量少的事**
- **推迟非关键行为**
- **结构：Top half & Bottom half**
  - Top half : 做最少的工作后返回
  - Bottom half ：推迟处理 (softirq, tasklets, 工作队列，内核线程)

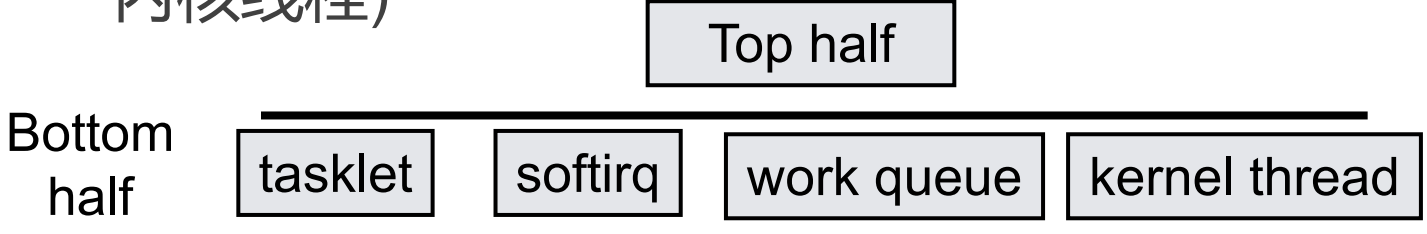

Top Half：马上做

- **最小的、公共行为**
  - 保存寄存器、屏蔽其他中断
  - 恢复寄存器，返回原来场景
- **最重要：调用合适的由硬件驱动提供的中断处理handler**
- **因为中断被屏蔽，所以不要做太多事情（时间、空间）**
- **使用将请求放入队列，或者设置标志位将其他处理推迟到bottom half**

Top Half：找到handler

- 现代处理器中，多个I/O设备共享一个IRQ和中断向量
- 多个ISR (interrupt service routines)可以结合在一个向量上
- 调用每个设备对应该IRQ的ISR

Bottom Half：延迟完成

- **提供一些推迟完成任务的机制**
  - softirqs
  - tasklets（建立在softirqs之上)
  - 工作队列
  - 内核线程
- **这些工作可以被中断**

注意：中断处理没有进程上下文

为什么？

- 中断（和异常相比）和具体的某条指令无关
- 也和中断时正在跑的进程、用户程序无关
- 中断处理handler不能睡眠！

中断处理中的一些约束

- **不能睡眠**
  - 或者调用可能会睡眠的任务
- **不能调用`schedule()`调度**
- **不能释放信号或调用可能睡眠的操作**
- **不能和用户地址空间交换数据**

中断和异常的处理

处理流程

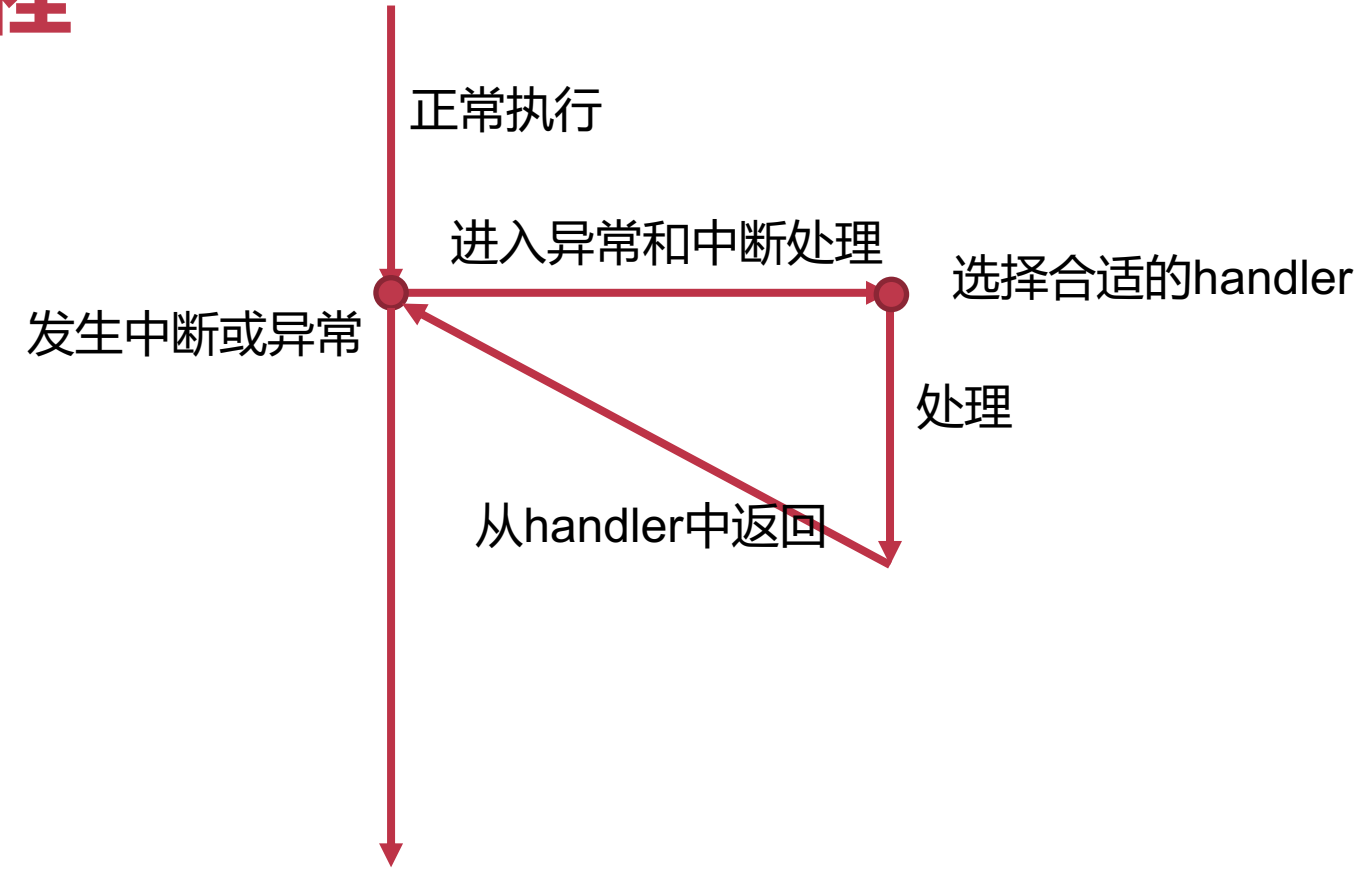

中断与异常的处理使用同一套机制，差异仅在选择handler中提现

中断和异常处理必做事项

- **进入中断或异常时**
  - 需保存处理器状态，方便之后恢复执行
  - 需准备好在高特权级下进行执行的环境
  - 需选择合适的异常处理器代码进行执行
  - 需保证用户态和内核态之间的隔离
- **处理时**
  - 需获得关于异常的信息，如系统调用参数、错误原因等
- **返回时**
  - 需恢复处理器状态，返回低特权级，继续正常执行流

AArch64的中断和异常处理

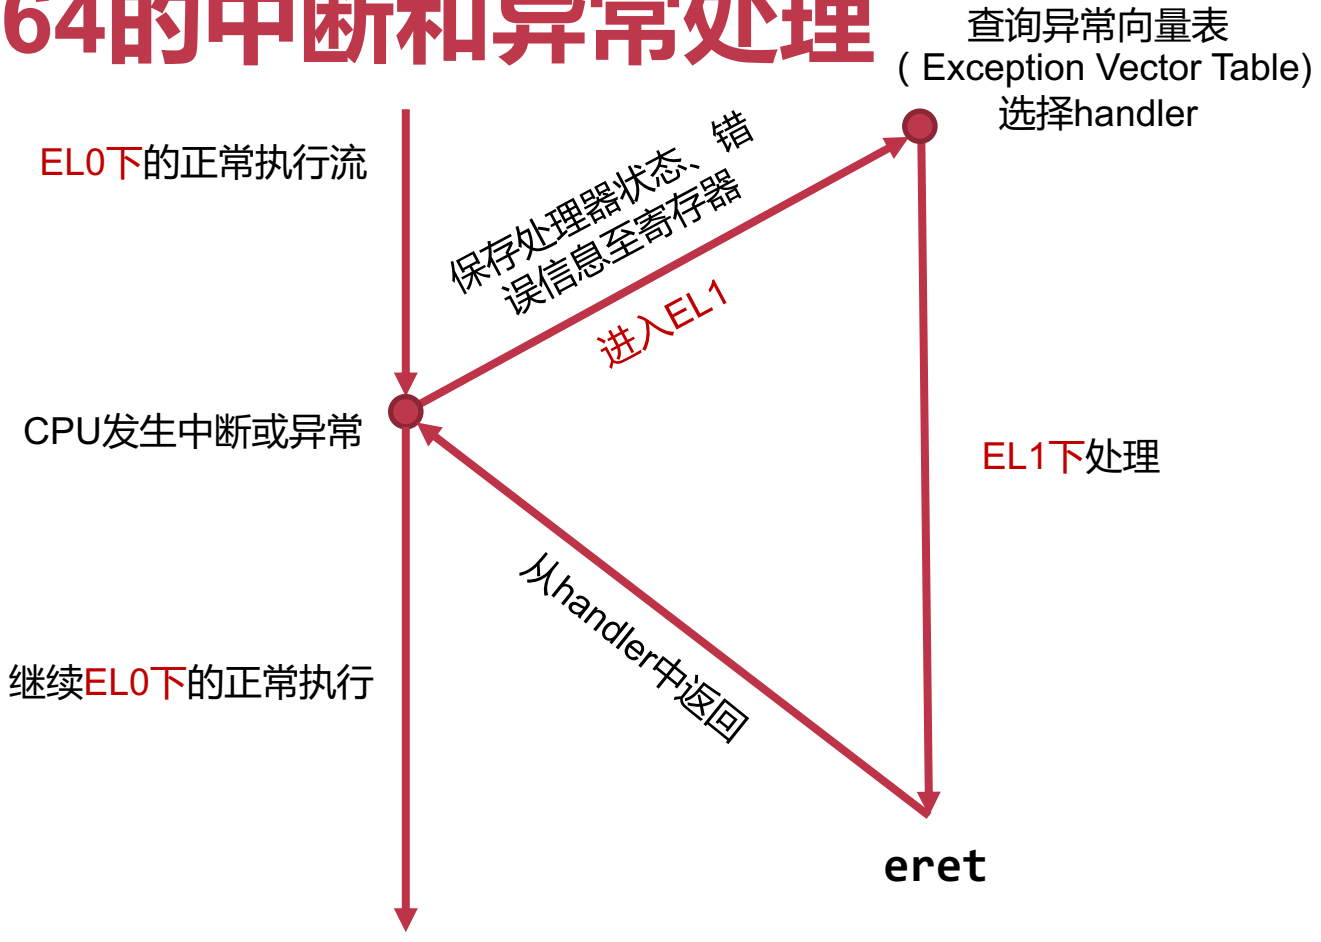

* 以EL0 -> EL1为例，后同

发生 – 信息保存

- **异常或中断发生后，硬件会将错误码和部分上下文信息存储在寄存器中**
  - 处理器状态（PSTATE）-> Saved Program Status Register（SPSR_EL1）
  - 当前指令地址（PC）-> Exception Link Register（ELR_EL1）
  - 异常发生原因 ->

  1) Serror与异常：Exception Syndrome Register（ESR_EL1）
  2) 中断：GIC中的寄存器（使用MMIO读取）

- **安全性问题**
  - 上述寄存器均不可在用户态（EL0）中访问

发生 – 进入EL1

- **硬件会适当修改处理器状态（PSTATE），进入EL1执行**
- **问题：栈内存的安全性**
  - 进入EL1级别后，栈指针（SP）会自动换用SP_EL1
  - 从而实现用户栈->内核栈
  - 如需在EL1下使用SP_EL0作为栈指针，可配置SPSel寄存器

寻找handler的代码

- **使用异常向量表（Exception Vector Table）**
  - 每个异常级别存在独立的异常向量表
  - 表项为异常向量（Exception Vector），是处理异常或跳转到异常handler的小段汇编代码
  - 地址位于VBAR_EL1寄存器中
  - 选择表项取决于
    - 异常类型（同步、IRQ、FIQ、Serror）
    - 异常发生的特权级
    - 异常发生时的处理器状态（使用的栈指针/运行状态）

VBAR_EL1

地址	异常类型	异常发生时处理器状态
+ 0x000	Synchronous	EL1 使用SP_EL0作为SP
+ 0x080	IRQ	
+ 0x100	FIQ	
+ 0x180	SError	
+ 0x200	Synchronous	EL1 使用SP_EL1作为SP
+ 0x280	IRQ	
+ 0x300	FIQ	
+ 0x380	SError	
+ 0x400	Synchronous	EL0 运行于AArch64状态
+ 0x480	IRQ	
+ 0x500	FIQ	
+ 0x580	SError	
+ 0x600	Synchronous	EL0 运行于AArch32状态
+ 0x680	IRQ	
+ 0x700	FIQ	
+ 0x780	SError	

VBAR_EL1

地址	异常类型	异常发生时处理器状态
+ 0x000	Synchronous	
+ (		L1 EL0作为SP
+ (		
+ (		
+ (		
+ 0x280	IRQ	EL1 使用SP_EL1作为SP
+ 0x300	FIQ	
+ 0x380	SError	
+ 0x400	Synchronous	EL0 运行于AArch64状态
+ 0x480	IRQ	
+ 0	Q	
+ (	rror	
+ (	ronous	EL0 运行于AArch32状态
+ (	Q	
+ (	Q	
+ 0x780	SError	

AArch64状态下，EL0中发生同步异常：
内存访问权限错误

- 保存上下文、错误信息
- 切换至EL1
- PC <- VBAR_EL1 + 0x400
- 开始执行

返回（Exception Return）

- **eret 指令**
  - ELR_EL1 -> PC，恢复PC状态
  - SPSR_EL1 -> PSTATE，恢复处理器状态
  - 降至EL0，硬件自动使用SP_EL0作为栈指针
  - 恢复执行

x86-64的中断和异常处理

- **进入异常**
  - 硬件会将上下文信息和错误码存储在内核栈上
- **用异常向量表寻找handler**
  - 不分级
  - 异常向量表中存handler的地址
- **`iret`返回**
  - 恢复程序上下文
  - 从内核态返回用户态
  - 继续执行用户程序

ChCore异常向量表配置

```
.align  11
EXPORT(el1_vector)
        exception_entry sync_el1t
        exception_entry irq_el1t
        exception_entry fiq_el1t
        exception_entry error_el1t

        exception_entry sync_el1h
        exception_entry irq_el1h
        exception_entry fiq_el1h
        exception_entry error_el1h

        exception_entry sync_el0_64
        exception_entry irq_el0_64
        exception_entry fiq_el0_64
        exception_entry error_el0_64

        exception_entry sync_el0_32
        exception_entry irq_el0_32
        exception_entry fiq_el0_32
        exception_entry error_el0_32
```

```
BEGIN_FUNC(set_exception_vector)
        adr     x0, el1_vector
        msr     vbar_el1, x0
        ret
END_FUNC(set_exception_vector)
```

```
.macro  exception_entry label
        .align  7
        b       label
.endm
```

每个异常向量均为简单的跳转指令

ChCore异常处理器

```
.align  11
EXPORT(el1_vector)
        exception_entry sync_el1t
        exception_entry irq_el1t
        exception_entry fiq_el1t
        exception_entry error_el1t

        exception_entry sync_el1h
        exception_entry irq_el1h
        exception_entry fiq_el1h
        exception_entry error_el1h

        exception_entry sync_el0_64
        exception_entry irq_el0_64
        exception_entry fiq_el0_64
        exception_entry error_el0_64

        exception_entry sync_el0_32
        exception_entry irq_el0_32
        exception_entry fiq_el0_32
        exception_entry error_el0_32
```

```
sync_el1t:
        handle_entry    1, SYNC_EL1t
```

```
.macro handle_entry el, type
    exception_enter      /* 保存内核软件需要的上下文 */
    mov x0, #\type       /* 准备参数 */
    mrs x1, esr_el1
    mrs x2, elr_el1
    bl  handle_entry_c   /* 调用C语言异常处理器，实际处理异常 */
    exception_return     /* 恢复内核软件需要的上下文 */
.endm
```

ChCore异常处理器

```
.macro handle_entry el, type
    exception_enter      /* 保存内核软件需要的上下文 */
    mov x0, #\type       /* 准备参数 */
    mrs x1, esr_el1
    mrs x2, elr_el1
    bl  handle_entry_c   /* 调用C语言异常处理器，实际处理异常 */
    exception_return     /* 恢复内核软件需要的上下文 */
.endm
```

```
void handle_entry_c(int type, u64 esr, u64 elr)
{
    /* ec: 异常类型（exception class） */
    u32 esr_ec = GET_ESR_EL1_EC(esr);

    switch (esr_ec) {
    case XXX:
            /* 处理异常XXX */
            /* ... */
    }
}
```

```
.macro  exception_enter
    /* 保存常规寄存器至内核栈 */
    sub sp, sp, #ARCH_EXEC_CONT_SIZE
    stp x0, x1, [sp, #16 * 0]
    stp x2, x3, [sp, #16 * 1]
    /* ... */
    stp x28, x29, [sp, #16 * 14]
    /* 保存一些特殊寄存器至内核栈 */
    mrs x21, sp_el0
    mrs x22, elr_el1
    mrs x23, spsr_el1
    stp x30, x21, [sp, #16 * 15]
    stp x22, x23, [sp, #16 * 16]
.endm

.macro  exception_exit
    /* 从内核栈恢复特殊寄存器 */
    ldp x22, x23, [sp, #16 * 16]
    ldp x30, x21, [sp, #16 * 15]
    msr sp_el0, x21
    msr elr_el1, x22
    msr spsr_el1, x23
    /* 从内核栈恢复常规寄存器 */
    ldp x0, x1, [sp, #16 * 0]
    ldp x2, x3, [sp, #16 * 1]
    /* ... */
    ldp x28, x29, [sp, #16 * 14]
    add sp, sp, #ARCH_EXEC_CONT_SIZE
    /* 结束异常执行 */
    eret
.endm
```

系统调用

系统调用（Syscall）

- 指运行在用户空间的程序向操作系统内核请求需要更高权限运行的服务
- 系统调用提供用户程序与操作系统之间的接口

系统调用方式 – 程序员视角

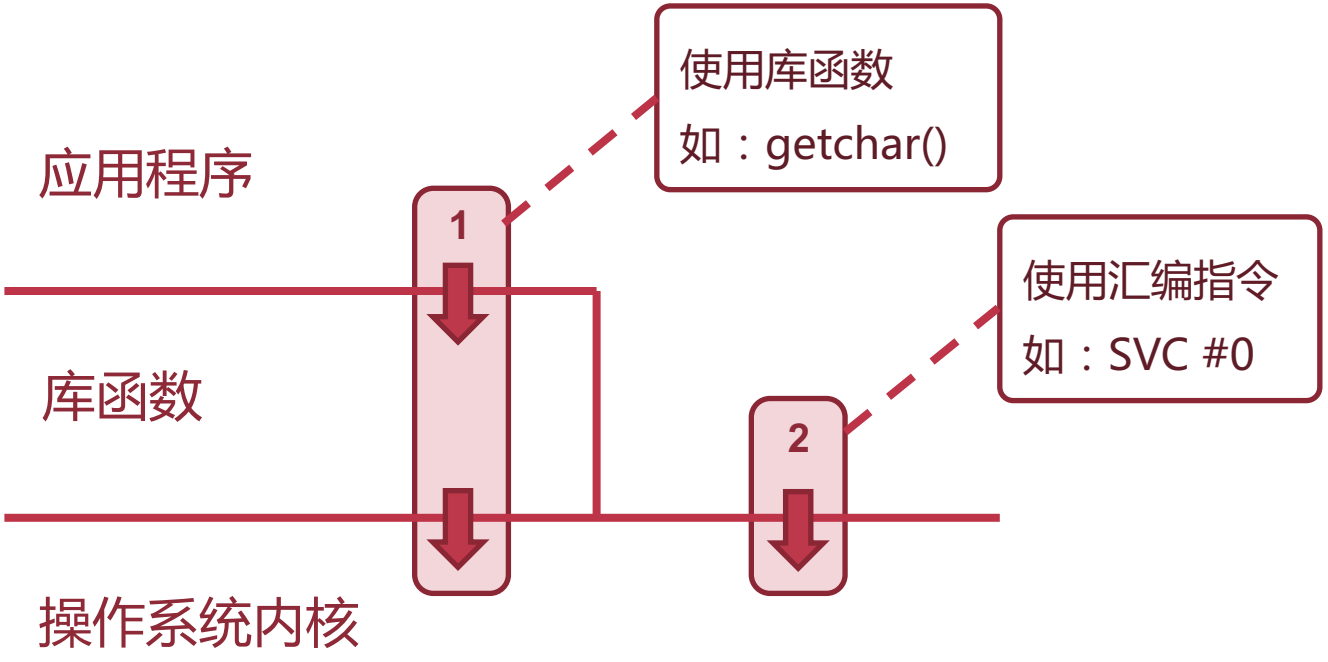

系统调用方式 – 硬件视角

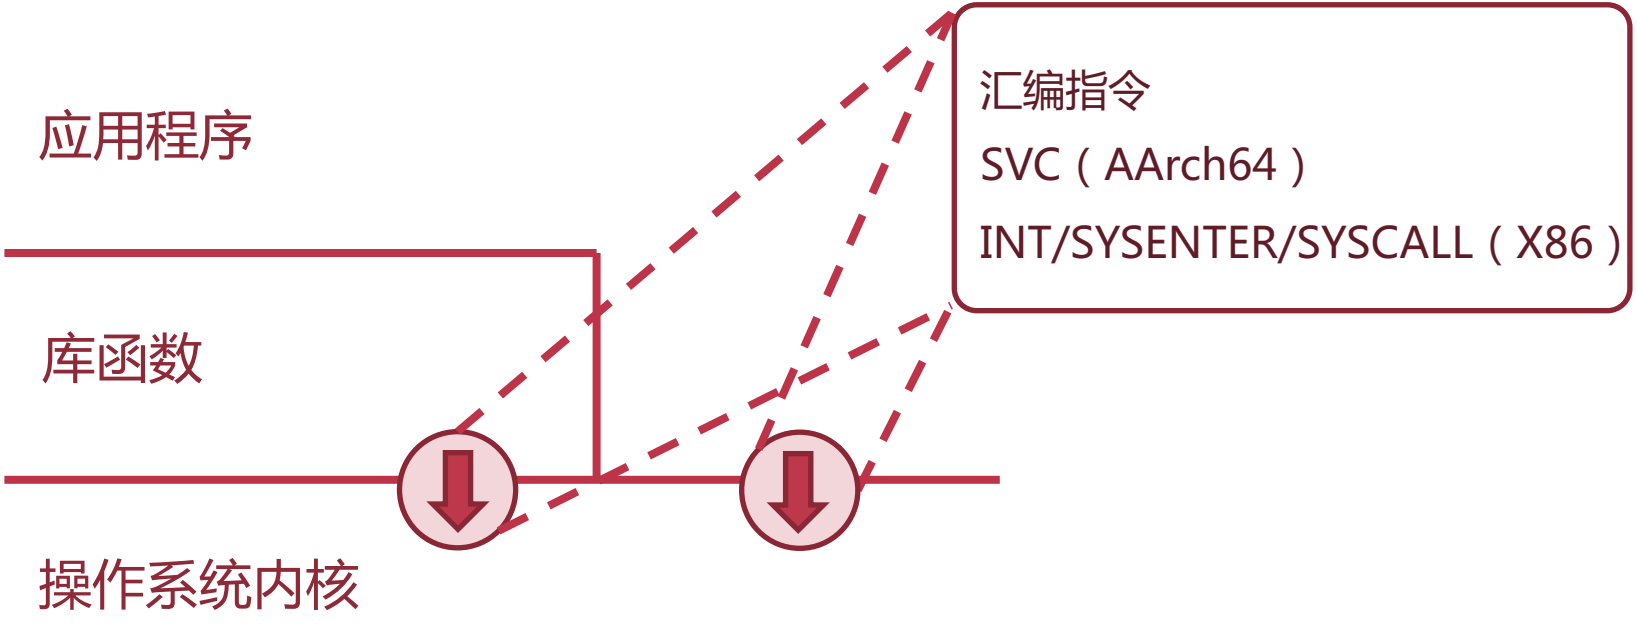

系统调用方式 – 硬件视角

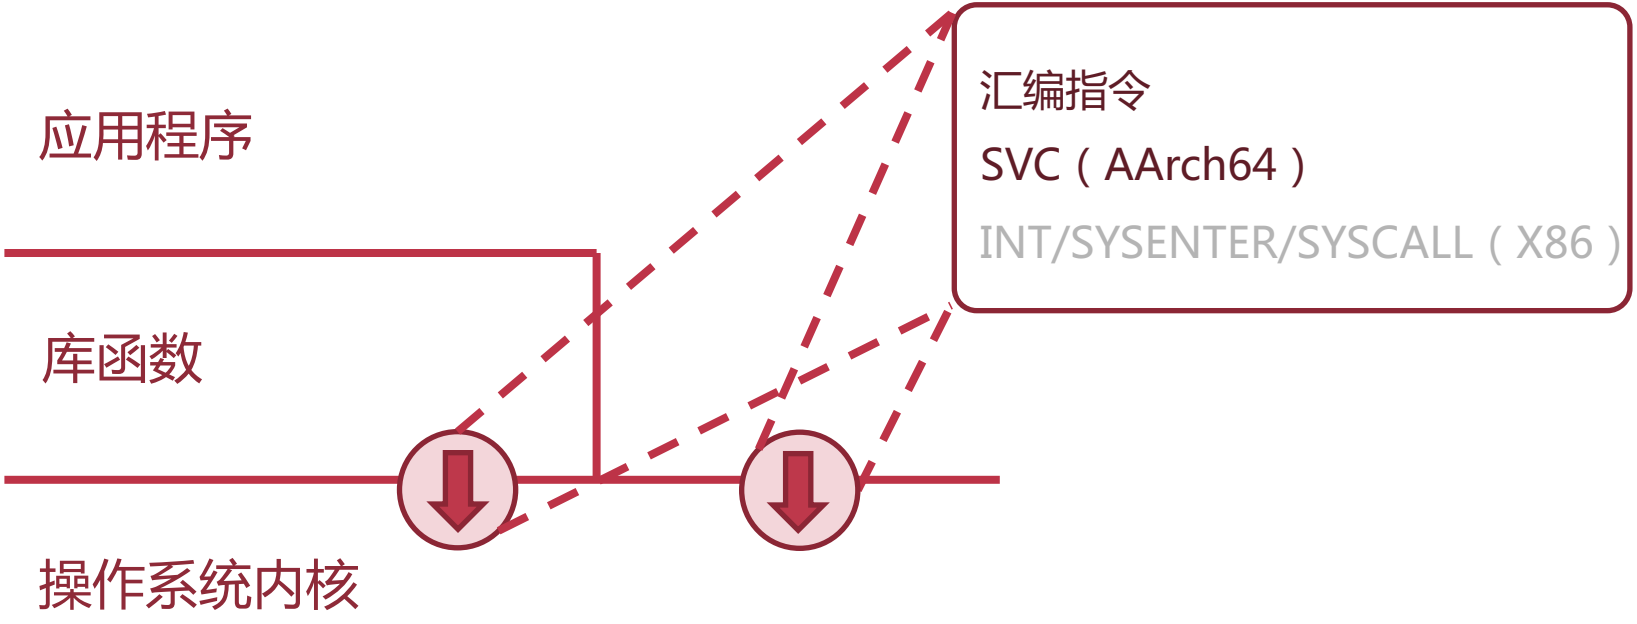

Linux的常用系统调用

Number	Name	Description	Number	Name	Description
1	exit	Terminate process	27	alarm	Set signal delivery alarm clock
2	fork	Create new process	29	pause	Suspend process until signal arrives
3	read	Read file	37	kill	Send signal to another process
4	write	Write file	48	signal	Install signal handler
5	open	Open file	63	dup2	Copy file descriptor
6	close	Close file	64	getppid	Get parent's process ID
7	waitpid	Wait for child to terminate	65	getpgrp	Get process group
11	execve	Load and run program	67	sigaction	Install portable signal handler
19	lseek	Go to file offset	90	mmap	Map memory page to file
20	getpid	Get process ID	106	stat	Get information about file

Linux追踪系统调用

- **每当有系统调用产生时，Linux可打印发生的系统调用、系统调用的参数和系统调用的返回值**
- **`ptrace()`可追踪Linux中的系统调用情况**
  - 广泛应用在各种debugger中
- **命令行中**
  - `strace`追踪系统调用
  - `ltrace`追踪库函数的调用

使用strace

```
int main() {
  write(1, "Hello world!\n", 13);
}
```

```
$ strace -o hello.out ./hello
```

```
execve("./hello2", ["./hello2"], [/* 59 vars */]) = 0
uname({sys="Linux", node="kiwi", ...}) = 0
brk(0) = 0xca9000
brk(0xcaa1c0) = 0xcaa1c0
arch_prctl(ARCH_SET_FS, 0xca9880) = 0
brk(0xccb1c0) = 0xccb1c0
brk(0xccc000) = 0xccc000
write(1, "Hello world!\n", 13) = 13
exit_group(13) = ?
```

案例分析：ChCore中的usys_exit()

- usys_exit：标明当前线程已返回

```c
void main(int argc, char *argv[], char *envp[])
{
    printf("hello, world\n");
    usys_exit(0);
}
```

```c
void usys_exit(int ret)
{
    syscall(SYS_exit, ret, 0, 0, 0, 0, 0, 0, 0, 0);
}
```

案例分析：ChCore中的usys_exit()

```
.align  11
EXPORT(el1_vector)
        exception_entry sync_el1t
        exception_entry irq_el1t
        exception_entry fiq_el1t
        exception_entry error_el1t

        exception_entry sync_el1h
        exception_entry irq_el1h
        exception_entry fiq_el1h
        exception_entry error_el1h

        exception_entry sync_el0_64
        exception_entry irq_el0_64
        exception_entry fiq_el0_64
        exception_entry error_el0_64

        exception_entry sync_el0_32
        exception_entry irq_el0_32
        exception_entry fiq_el0_32
        exception_entry error_el0_32
```

```
syscall(u64 sys_no, u64 arg0, u64 arg1, u64 arg2, /* ... */)


u64 ret = 0;
asm volatile ("mov x8, %1\n"
              "mov x0, %2\n"
              "mov x1, %3\n"
              "mov x2, %4\n"
              /* ... */
              "svc #0\n"
              "mov %0, x0\n"
              :"=r" (ret)
              :"r"(sys_no), "r"(arg0), "r"(arg1), "r"(arg2),
              /* ... */
              :"x0", "x1", "x2", "x3", "x4", "x5", "x6", "x7", "x8"
);
return ret;
```

系统调用与安全

- **AArch64使用寄存器传参，个数有限**
  - 如ChCore的系统调用支持使用寄存器X0-X7最多8个参数
- **若系统调用需要更多参数如何处理？**
  - 使用结构体打包参数，并将结构体的指针作为参数
- **问题：内存安全性**
  - 作为参数的指针必须经过检测！
  - 指向NULL -> kernel crash
  - 指向内核内存 -> 安全漏洞

用户指针检测

- **完备的指针检测十分耗时**
  - 需要遍历用户进程的所有合法内存区域进行检测
- **Linux解决方法：非全面检查**
  - Linux仅**初步检测**用户指针是否属于对应进程的用户内存区域的**最大可能边界**
  - 即使通过初步检测，用户指针**仍然可能非法**（如指向尚未分配的栈空间等）
  - 直接将**非法的指针**交给内核使用会导致内核出现**页错误**，内核态的页错误通常以为着bug，内核会打印异常信息并中止用户进程
  - Linux采用了一些复杂机制来防止这一情况发生

处理用户指针问题

- **内核代码仅使用特定代码片段访问用户指针（如copy_from_user）**
  - 由访问用户指针而导致内核内存错误的代码段是确定的
- **当内核发生页异常（Page Fault）时，内核会检查异常发生的PC**
  - 若异常发生的PC属于访问用户指针的代码段，Linux尝试对其进行修复
  - 若不属于，则报告问题并终止用户程序
- **然而**
  - Linux中很多地方违反了这一规定，导致了许多安全漏洞

系统调用与性能

- **系统调用会造成大量性能开销**

- **硬件优化：新的系统调用指令**
  - x86提出了syscall/sysenter/sysexit来代替int进行系统调用

- **软件优化**
  - 开放性问题

教材相关章节

- 第2.1.2节：特权级
- 第2.3节：设备与中断
- 第10.3节：设备的中断处理

下次课内容

- 操作系统结构